

フィジカル空間情報を用いた 5G スループット予測技術

永田 尚志[†] 工藤 理一[†] 高橋 馨子[†] Ramesh Eshan[†] 小川 智明[†]
青木 祐也^{††} 堀瀬 友貴^{††} 森広 芳文^{††}

[†] NTT 未来ねっと研究所フロンティアコミュニケーション研究部 〒239-0847 神奈川県横須賀市光の丘 1-1

^{††} NTT ドコモ 6G-IOWN 推進部 〒239-8536 神奈川県横須賀市光の丘 3-5 NTT ドコモ R&D センタ

E-mail: [†]hisashi.nagata.zu@hco.ntt.co.jp

あらまし 無線通信技術の発展により、あらゆるモノがネットワークに接続され、様々なアプリケーションの創出が期待されている。多様化するアプリケーションにより、無線通信に対して高速・低遅延・高信頼などの高度な要件が生じ、増加するモバイルトラフィックに対して大容量化が必要となる。ミリ波の利用はモバイルネットワークの容量増加には有効であるが、高信頼に対して課題がある。ミリ波の無線リンクは通信端末の見通しと周囲物体による遮蔽がリンクの品質を低下させる可能性がある。本稿では、フィジカル空間情報として通信端末とその周辺物体の位置・速度・方向を用いた 5G スループット予測技術を提案する。フィジカル空間情報は、無線通信領域における物体の動きを予測でき、スループットの予測精度向上に繋がる。提案手法の有効性の評価のため、自立型移動ロボットと商用の 5G ネットワークを用いた屋内実験環境で実験を行った。実験により、ディープニューラルネットワークを用いた提案手法による予測は、従来の過去のスループット情報を用いた予測手法に比べて、最大 38.4 % の精度向上を実現した。
キーワード 5G, ミリ波, 深層学習, フィジカル空間情報, 通信品質予測

5G throughput prediction using physical space information

Hisashi NAGATA[†], Richi KUDO[†], Kahoko TAKAHASHI[†], Ramesh ESHAN[†], Tomoaki OGAWA[†],
Yuya AOKI^{††}, Yuki HORISE^{††}, and Yoshifumi MORIHIRO^{††}

[†] Frontier Communication Laboratory, NTT Network Innovation Laboratories 1-1 Hikarinooka Yokosuka-Shi
Kanagawa, 239-0847 Japan

^{††} 6G-IOWN Promotion Department, NTT DOCOMO R&D Center, 3-5 Hikarinooka Yokosuka-Shi Kanagawa,
239-8536 Japan

E-mail: [†]hisashi.nagata.zu@hco.ntt.co.jp

Abstract Given the recent advances in wireless communication technology, all things are being connected to networks, and it is expected that various new applications will be created. The diversification in applications will yield various requirements such as high speed, low latency and/or high reliability for wireless communication, while large capacity is needed to manage the increasing mobile traffic. Although the millimeter-wave use is a promising to increase the capacity of mobile network, it is a big challenge for millimeter-wave channel to satisfy the reliability requirements. The millimeter-wave wireless links require a line of sight (LOS) environment and shadowing by objects can degrade their link qualities. In this paper, we propose the 5G throughput prediction scheme that uses physical space information of the position, velocity and direction of the user terminal and surrounding objects. The physical space information enables to predict movements of the objects in the wireless communication area and improves the prediction accuracy. To evaluate the effectiveness of the proposed prediction, we conducted the indoor experiments using commercial 5G network and the autonomous mobility robots. The experiments show that the proposed prediction based on deep neural network (DNN) improves by up to 38.4 % compared to the conventional prediction using the past throughput information.

Key words 5G, millimeter-wave, deep learning, physical space information, communication quality prediction

1. ま え が き

無線通信システムは進歩している。LTE が広く普及し、高速通信がどこでも利用できるようになりつつあるほか、高速、大容量、多数端末接続、高信頼、低遅延の要件 [1], [2] を満たすために 5G (5th Generation) サービスも始まっている。このような無線通信品質の進歩により、接続されるデバイスが増加している。特に 5G により、高速・低遅延・高信頼を要求する新サービスを創出することが期待されている。さらに、モバイルトラフィックの増大をしており、それをカバーするため、ミリ波チャンネルのような高周波帯を利用していく必要がある [3]。ミリ波やサブテラヘルツ波（～300 GHz 帯）は、将来の beyond 5G のネットワーク基盤の鍵となる [4]。

高信頼なミリ波を可能にするための研究がされている。理想的な見通しの環境下では、ミリ波による通信は高速で高いパフォーマンスを実現する。一方、見通し外の環境下では、ミリ波の品質は通信範囲における障害物の影響によって低下しやすい [5]。ミリ波によって接続されるアプリケーションには多くの課題があり、ユーザの移動により、ミリ波のシステムパフォーマンスに影響を与える [6]。

無線リンク品質の予測に対して、ディープニューラルネットワーク (DNN) を用いた手法が提案されている。ミリ波における高信頼な無線通信を実現するため、人が遮蔽するシナリオでの深度カメライメージを用いた DNN によるリンク品質予測が提案されている [7]。このように無線通信に対する深層学習の適用については、無線リンク品質の予測技術の重要な要素技術の 1 つとなっている [8], [9]。

さらに、2030 年に向けて提案されている Society 5.0 [10] では、サイバー（仮想）空間とフィジカル（物理）空間の情報を融合して、新しいサービスや価値を生み出すことが期待されている。そのような世界では、あらゆる情報がネットワーク上で収集・管理されると予期される。環境に設置されたカメラ・センサなども今後普及が進み、将来の無線リンク品質予測システムに活用されることが期待されている。Wi-Fi においてフィジカル空間情報としてカメライメージから取得した通信端末を所持した移動型ロボットのバウンディングボックス位置情報などを用いたリンク品質予測に対する有効性が示されている [11], [?]。これらの研究は、カメライメージや位置情報などのフィジカル空間情報が、数百ミリ秒以上先の長期予測に対して効果的であることを示している [13], [14]。

本稿では、ミリ波チャンネルによる高信頼なリンクを実現するため、ユーザ端末 (UE) の位置や方向や速度といったフィジカル空間情報を用いた DNN に基づくリンク品質予測技術を提案する。予測精度の評価のため、自律型移動ロボットと人体の比誘電率・導電率を模擬した人形を組み合わせることで歩行者を再現することで、歩行シナリオにおけるフィジカル空間情報を自動で収集可能な 5G 検証フィールドを屋内環境に構築し、深層学習に必要なビッグデータを収集した。この自立型移動ロボットは robot operation system (ROS) で制御されており、自立型移動ロボットに設置した Light Detection And Ranging (LiDAR) から

取得した 2 次元点群情報から Adaptive Monte Carlo Localization (AMCL) [15] で自己位置推定をすることで周囲の障害物などとの衝突回避をして移動と停止をランダムに繰り返すようにランダム性を与えて制御している。また、この人型ロボットには UE を掲載し、5G 基地局を通じてクラウド上のサーバと通信をさせてスループットを計測しており、そのときの 5G スループットを予測させた。その人型ロボット以外にターゲットとなる UE の周辺を動く人型ロボットを用意した。実験は 11 日間にわたる計約 41 時間に相当するデータセットを取得した。

DNN による予測モデルには、フィジカル空間情報を入力する提案手法と、精度比較のために過去のスループットを入力する従来手法を用いた。予測モデルは約 41 時間に相当するデータを用いて訓練をし、1 秒後の 5G スループットを予測させた。特に、フィジカル空間情報として通信端末の位置や方向、速度情報を入力することに加えて、その通信端末の周辺環境情報を用いることで、周辺環境によって生じる遮蔽に対するスループット変動予測に有効であることを示した。

本稿では、2 章でシステムモデルと予測モデルとその入力データであるフィジカル空間情報の概要について、3 章では、提案手法を評価した屋内実験環境の紹介と、フィジカル空間情報を用いた予測モデルの入力データの詳細説明について、4 章では、提案手法の予測精度を評価について、5 章で結論を述べる。

2. システムモデル

システムモデルはの全体像は図. 1 の通りである。人がユーザ端末 (UE) を所持し、アプリケーションを利用している。UE はサービス利用のために 5G 基地局と通信している。このシステムでは、フィジカル空間情報として予測対象の UE とその周辺の UE の位置・方向・速度の状態とリンク品質を収集して、予測モデルに入力して将来のリンク品質を予測する。

数秒後の予測されたリンク品質は仮想現実 (VR) や拡張現実 (AR) のような多様なアプリケーションを安定的に利用するために活用される。本稿では、5G システムに焦点を当て、リンク品質における数秒後などの長期予測を検討する。

2.1 リンク品質

リンク品質は 5G システムにおいて、時間幅 ΔT の平均スループットとして定義する。時刻 t_i のときの時間幅 ΔT におけるスループット $R[t_i]$ は、

$$R[t_i] = \frac{1}{\Delta T} \sum_{t_i - \Delta T < t \leq t_i} B[t], \quad (1)$$

と表現できる。 $B[t]$ は時刻 t において受信できたビット量である。予測時間を t_m とすると、予測するスループット $R[t_m]$ となる。現在時刻を t_0 とすると、現在時刻との差である $t_m - t_0$ 秒後を予測することを意味する。

2.2 フィジカル空間情報

本システムモデルでは、全ての UE の位置や方向、速度を状態として取得し、それらを用いた予測モデルへの入力データを Φ で定義する。予測対象の UE のスループットが測定されたとき、時刻 t におけるその UE の状態を用いた入力データは

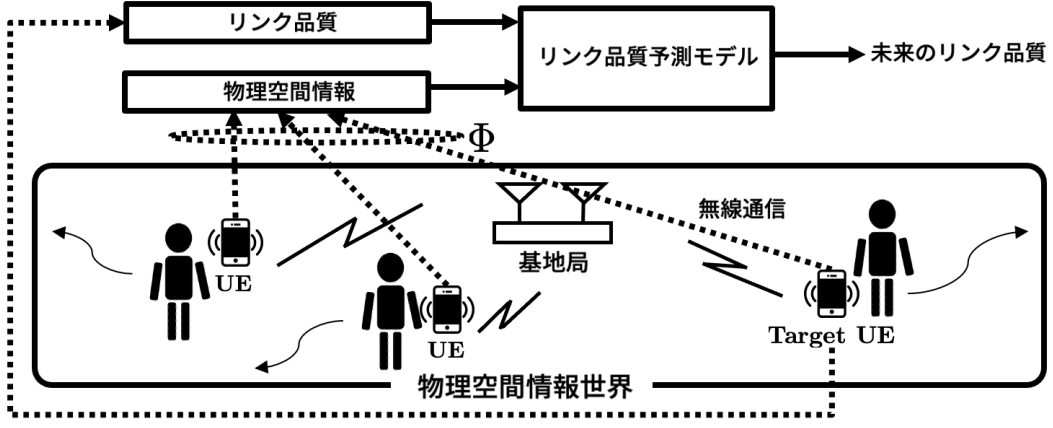


図1 システムモデル

$\Phi_A[t]$, その周囲の UE の状態を用いた入力データを $\Phi_B[t]$ と定義する. 全ての UE の状態は, 無線リンクやカメラ, センサを経由して UE から取得される. 本稿では, 予測対象の UE と遮蔽用の UE を用意し, 2次元のフィジカル空間情報が利用できる環境を想定する. そのため, UE の高さは考慮されない. 予測対象の UE と遮蔽用 UE の状態は,

$$\phi_A = \{\mathbf{x}_A, \theta_A, \mathbf{v}_A\}, \quad (2)$$

$$\phi_B = \{\mathbf{x}_B, \theta_B, \mathbf{v}_B\}, \quad (3)$$

で与えられ, $\mathbf{x}_A, \theta_A, \mathbf{v}_A$ はそれぞれ, UE の位置ベクトル, 方向ベクトル, 速度ベクトルを表す. UE の状態の詳細は 3. 章で議論する.

2.3 スループット予測

5G のリンク品質予測に対して, フィジカル空間情報を用いた提案手法との比較のため, スループット情報を用いた予測手法と比較評価を行った. リンク品質として 5G のスループットを扱った. スループット予測モデルは過去のスループットと予測対象の UE の状態と, 遮蔽用 UE の状態を用いる. 本稿では, $\Phi_T, \Phi_A, \Phi_{AB}, \Phi_{AT}, \Phi_{ABT}$ の 5 つの入力データを用いてスループット予測を行い, 入力データはそれぞれ,

$$\Phi_T = (R[t_{-D+1}], \dots, R[t_0]), \quad (4)$$

$$\Phi_A = (\phi_A[t_{-D+1}], \dots, \phi_A[t_0]), \quad (5)$$

$$\Phi_{AB} = (\phi_A[t_{-D+1}], \phi_B[t_{-D+1}], \dots, \phi_A[t_0], \phi_B[t_0]), \quad (6)$$

$$\Phi_{AT} = (\phi_A[t_{-D+1}], R[t_{-D+1}], \dots, \phi_A[t_0], R[t_0]), \quad (7)$$

$$\Phi_{ABT} = (\phi_A[t_{-D+1}], \phi_B[t_{-D+1}], R[t_{-D+1}], \dots, \phi_A[t_0], \phi_B[t_0], R[t_0]), \quad (8)$$

とした. Φ_T は過去スループット, Φ_A は予測対象 UE の状態, Φ_{AB} は予測対象と遮蔽用 UE の状態, Φ_{AT} は過去スループットと予測対象 UE の状態, Φ_{ABT} は予測対象の UE と過去スループット, Φ_{ABT} は予測対象と遮蔽用 UE の状態と過去スループットをそれぞれ入力して予測させた.

スループットと UE の状態は深層学習による 5G スループット予測モデルの訓練データとして測定され, 時刻 t_0 における入力データ $\Phi_s[t_0]$ から将来のスループット $\hat{R}_s[t_m]$ を予測するモ




図2 スループット予測モデルにおける DNN 構成

デルを生成するために用いられ, その将来スループットを出力する関数 f_s は,

$$\hat{R}_s[t_m] = f_s(\Phi_s[t_0]), \quad (9)$$

で与えられる. インデックス $s \in \{T, A, AB, AT, ABT\}$ は 5 種類の入力データを表す. 各々の入力データに対する予測モデルのスループット予測精度を評価するため, 平均絶対誤差 (MAE) の指標を用いる. 入力データ Φ_s に対する MAE は,

$$\text{MAE}_s = \sum_k |R[t_k] - \hat{R}_s[t_k]|, \quad (10)$$

となり, インデックス k はテストデータを表しており, 全てのテストデータの誤差を合計して平均した値で評価を行う.

2.4 スループット予測モデル

スループット予測モデルの DNN 構成を図. 2 に示す. 予測モデルには, Recurrent Neural Network(RNN) と全結合 (FC) の層から構成される DNN を用いる. 第 1 層の RNN には a Long short-term memory (LSTM), 第 2 層と第 3 層には FC 層を用いており, 出力次元数はそれぞれ 64, 64, 32 としている. また, FC 層の間には 10 % のドロップアウト, FC 層の出力には活性化関数として Rectified Linear Unit (ReLU) を用いている. 最適化アルゴリズムには Adaptive Moment Estimation(Adam), 学習率は 0.0005 とした. 損失関数にはスループット観測値と予測値の平均二乗誤差 (MSE) とし, それを最小化するように訓練した.

3. 屋内実験環境設定

5G スループット予測精度を評価するために, 屋内に 5G 検証



図3 UE-A



図4 UE-B for blocking




図5 屋内実験環境マップ

フィールドを構築した。UE を所持した 2 人が屋内を歩行しながら、一方の UE が 28 GHz チャンネルを含む 5G 経由で通信しているときの歩行者シナリを想定した。

歩行者シナリオに対して、DNN で構成されるスループット予測モデルを学習させるために必要となるビッグデータ生成のため、自律走行する人型ロボットを用意した。人型ロボットは人形と移動ロボットの組み合わせで構成される。UE-A は図. 3 の通りで、通信している予測対象 UE をバックパックの中に所持させている。UE-B は図. 4 の通りで、UE-A を遮蔽するように走行させている。土台の移動ロボットを含めて、UE-A と UE-B はそれぞれ 167, 170 cm の高さである。土台の移動ロボットは、対向 2 輪型ロボットを活用し、LiDAR を搭載しており、周辺的环境情報を 2 次元点群データとして取得して障害物との衝突を回避して連続走行を可能としている。

図. 5 は、実際の屋内実験環境のマップである。図. 5 に示す通り、UE-A と UE-B は異なる 2 つずつのゴール地点を設定しており、UE-A と UE-B についてそれぞれ $\mathbf{x} = (6.0, -2.5)$, $(6.0, 4.5)$ と $\mathbf{x} = (5.0, -2.5)$, $(5.0, 3.0)$ の座標である。それぞれの UE はこのゴール地点を端点としてその間を往復直線運動するように ROS で制御している。また、走行中にランダムに移動と停止をするようにし、走行にランダム性を与えている。実際の走行ルートは UE-A と UE-B について、それぞれ図. 5 の青線と赤線

表 1 Experimental setup

基地局	28 GHz チャンネルを含む商用網 5G
アンテナ高	UE-A: 1.0 m 基地局: 2.65 m
トランスポートプロトコル	UDP
伝送	Uplink




図6 移動ロボットシステム情報; (a) 位置と方向, (b) 回転・進行方向速度

でプロットした。UE-B は UE-A と基地局の間を走行するように設定しており、UE-A と基地局の間を見通しを遮る事象が発生する。また、UE は最高速度を 1.0 m/s で走行させている。

3.1 スループット計測

表. 1 は通信に関する実験諸元を表している。5G スループット計測には iperf [16] のツールを活用し、商用網の 5G 基地局を経由して UE-A とクラウド上のサーバとの間でアップリンクで UDP によりパケット転送することで 0.1 s 間隔で収集した。収集したスループットは、時間幅 $\Delta T = 1.0s$ で平均化して利用した。アンテナ高については、5G 基地局は 2.65 m で、UE-A はバックパックの中に UE を所持しており、1 m の高さである。

3.2 フィジカル空間情報と測定

UE の土台である移動ロボットには LiDAR が搭載されており、レーザ信号の反射点による点群データに対して Adaptive Monte Carlo Localization (AMCL) に基づいたアルゴリズムを適用することで、点群データとフィールドマップとの比較により自己位置・方向・速度を推定する。移動ロボットから得られる状態は図. 6 に示す。時刻 τ_i のときの位置ベクトル $\mathbf{x}[\tau_i]$ は $\mathbf{x}[\tau_i] = \{x[\tau_i], y[\tau_i]\}$ と表現される。時刻 τ_i のときの速度ベクトル $\mathbf{v}[\tau_i]$ は

$$\theta[\tau_i] = (k[\tau_i], \omega[\tau_i]) = (\sin(\theta[\tau_i]/2), \cos(\theta[\tau_i]/2)), \quad (11)$$

で与えられ、 $\theta[\tau_i]$ は方位角を表す。さらに、時刻 τ_i のときの速度ベクトル $\mathbf{v}[\tau_i]$ は、

$$\begin{aligned} \mathbf{v}[\tau_i] &= (v[\tau_i], \dot{\theta}[\tau_i]) \\ &= (L(\omega_1[\tau_i] + \omega_2[\tau_i])/2, L(\omega_1[\tau_i] - \omega_2[\tau_i])/2), \end{aligned} \quad (12)$$

で与えられ、 L は車輪半径、 d は 2 つの車輪間の軸方向距離、 ω_1 と ω_2 はそれぞれ左右の車輪の角速度である。それぞれの UE から UE-A と UE-B のこれらの状態を収集した。もし、ある時刻において収集できなく欠損が発生した場合は、直近のデー




図7 5回の交差検証を実施したときの入力データごとの絶対平均誤差

タで代用した。

3.3 訓練と精度評価のためのデータセット

5G スループットと UE-A と UE-B の状態を 0.1 s 間隔で収集した。構築した屋内の 5G 検証フィールドで 11 日間にわたり実験を行い、計約 41 時間に相当する 1,493,750 サンプルのデータセットを用意した。これらのデータセットの値は学習のために、0 から 1、または -1 から 1 の範囲でスケールしている。また、学習は 5 回の交差検証を実施しており、全てのデータセットの内の 25 % のサンプルをテストデータ、それ以外のデータセットの内の 90 % のサンプルを訓練データ、10 % のサンプルを評価データとして学習させた。

5G スループットに関しては、最小値が 0.1 Mbps で、最大値が 463 Mbps で、平均値が 213 Mbps であった。このように高いスループット値が観測されており、UE-A は 28 GHz チャンネルを含む 5G に接続されていたことがわかる。スループットについては時間幅 $\Delta T = 1.0$ s、つまり 10 フレーム分で平均値を取って利用する。また、本予測技術を 5G に接続されたアプリケーションなどの制御に利用するときに、スループットの低下を予測することが重要となる。そのため、スループットの低下を重点的に学習させるため、スループットの上限を 200 Mbps に設定して予測を行なった。

4. 評価結果

DNN に基づく 5G スループット予測モデルに対する入力データは、過去のスループットと UE の状態の組合せで構成される 5 種類を用意した。入力データは全て 1.0 s 間に相当する $D = 10$ とした時系列データとした。

4.1 5G スループット予測モデルに関する精度評価

図. 7 は、5 回の交差検証を実施したときのスループットの予測値と観測値との間の MAE を表す。今回の実際の屋内実験環境では、入力データである $\Phi_T, \Phi_A, \Phi_{AB}, \Phi_{AT}, \Phi_{ABT}$ に対する 5 回の MAE はそれぞれ、19.33, 17.86, 16.37, 14.68, 13.82 Mbps となった。2 つの UE の状態を入力した提案手法である Φ_{AB} と過去スループットのみを入力した従来手法である Φ_T




図8 観測値と予測値との間の絶対誤差に関する CDF

を比較し、提案手法は 15.3 % の精度が向上した。この結果から、5G スループット予測に対して、過去のスループットよりもフィジカル空間情報の方が相関性が高く、予測に重要な要素であることがわかった。また、UE-A の状態に UE-B の状態を加えると、UE-A のみと比較して、8.3 % の精度が向上した。予測対象の UE-A だけでなく、周辺情報の UE-B の状態が予測に重要であることがわかった。過去スループットのみを入力データでは最も精度が低かったが、UE-A と UE-B の状態と組み合わせることで予測精度は向上し、過去スループットのみと比較して、28.5 % の精度が向上を実現した。

図. 8 は、スループットの予測値と観測値との間の絶対誤差に対する累積分布関数 (CDF) を示している。 $\Phi_T, \Phi_A, \Phi_{AB}, \Phi_{AT}, \Phi_{ABT}$ の入力データに対する 50 パーセンタイル値を見ると、それぞれ 9.85, 9.18, 6.07, 6.40, 4.18 Mbps となった。2 つの UE の状態を入力した提案手法である Φ_{AB} と過去スループットのみを入力した従来手法である Φ_T を比較し、提案手法は 38.4 % の精度が向上した。図. 7 の結果と同様に、入力データに関して、過去スループットのみが最も精度は低く、UE-A と UE-B の状態と過去スループットを組み合わせることで最も精度は高くなった。

4.2 入力データ評価

図. 9 はスループットの予測値と観測値に関して、約 1000 サンプルのテストデータを 100 ms 間隔でプロットした結果であ




図9 スループットの観測値と予測値の時系列プロット結果

る。黒の実線は観測値を示しており、200 Mbps から数十 Mbps に急激に低下する箇所があることがわかる。赤と青の点線は、それぞれ Φ_{AB} と Φ_A を入力して予測した結果である。双方とも、そのような急激なスループット変動に対して追従して予測できていることがわかる。 Φ_{AB} と Φ_A の結果を比較すると、図9のグレー部分で結果が異なることがわかる。この箇所は、スループットが低下する箇所であり、 Φ_{AB} ではその予測ができていたが、 Φ_A では予測ができていない箇所である。これは UE-B の遮蔽によるスループット低下であり、予測対象の UE-A の状態だけでなく、周辺環境情報として UE-B の情報を入力データに加えることでそのような遮蔽効果を学習できたためだと考えられる。

5. 結 論

本稿では、LSTM と FC 層から構成される DNN に基づくフィジカル空間情報を用いた 5G スループット予測技術を提案した。提案手法では、フィジカル空間情報として通信端末の位置・方向・速度だけでなく、その周辺情報を加えた手法を提案した。提案手法の評価と DNN に必要となるビッグデータを収集するため、ROS で制御された人型ロボットを用いることで、自動的にフィジカル空間情報を収集できる 5G 検証フィールドを構築し、11 日間にわたる計 41 時間の計測に相当する 1,493,750 サンプルを収集し、通信端末だけでなく周辺のフィジカル空間情報が 5G スループット予測に効果的であることを示した。周辺のフィジカル空間情報を加えることで、MAE で 8.3 % の精度が向上し、さらに、従来技術である過去スループットを入力したときの予測精度と比較して、15.3 % の精度が向上した。

時間 [s]

スループット [Mbps]

文 献

- [1] T. Nakamura, S. Nagata, H. Umeda, H. Takahashi, and K. Ando, "Special Articles on LTE-Advanced Release 13 Standardization," NTT DOCOMO Technical Journal Vol. 18, No.2, 2016.
- [2] P.C. Jain, "Recent trends in next generation terabit Ethernet and gigabit wireless local area network," In Proc. Of 2016 International Conference on Signal Processing and Communication (ICSC), pp. 106-110. IEEE, 2016.
- [3] C. Dehos, J. L. González, A. De Domenico, D. Kténas, and L. Dussopt, » "Millimeter-wave access and backhauling: the solution to the » exponential data traffic increase in 5G mobile communications » systems," IEEE Commun. Mag., vol. 52, no. 9, pp. 88-95, » Sep. 2014.
- [4] https://www.docomo.ne.jp/english/binary/pdf/corporate/technology/whitepaper_6g/DOCOMO_6G_White_PaperEN_v5.0.pdf
- [5] Wang, X., Kong, L., Kong, F., Qiu, F., Xia, M., Arnon, S., and Chen, G, "Millimeter wave communication: A comprehensive survey," IEEE Communications Surveys and Tutorials, vol. 20, no. 3, pp. 1616-1653, » third quarter 2018.
- [6] J. Li, Y. Niu, H. Wu, B. Ai, S. Chen, Z. Feng, Z. Zhong, N. Wang, » "Mobility Support for Millimeter Wave Communications: » Opportunities and Challenges," IEEE Communications Surveys and Tutorials, vol. 24, no. 3, » pp. 1616-1653, third quarter 2022.
- [7] T. Nishio et al., "Proactive Received Power Prediction Using Machine Learning and Depth Images for mmWave Networks," in IEEE Journal on Selected Areas in Communications, vol. 37, no. 11, pp. 2413-2427, Nov. 2019, doi: 10.1109/JSAC.2019.2933763.
- [8] C. Zhang, P. Patras, H. Haddadi, "Deep learning in mobile and wireless networking: survey," IEEE Communications surveys & tutorials vol. 21(3), pp. 2224-2287, Mar. 2019.
- [9] A. Salh, L. Audah, et al., "A Survey on Deep Learning for Ultra-Reliable and Low-Latency Communications Challenges on 6G Wireless Systems," IEEE Access, Mar. 2021.
- [10] https://www8.cao.go.jp/cstp/society5_0/index.html
- [11] R. Kudo, K. Takahashi, T. Murakami, T. Ogawa, "Deep Learning based Link Quality Prediction for Autonomous Mobility Robots", IEICE Tech. Rep., vol. 120, no. 321, SIP2020-80, pp. 218-223, Jan. 2021.
- [12] H. Nagata, R. Kudo, K. Takahashi, T. Ogawa and K. Takasugi, "Two-step wireless link quality prediction using multi-camera images," 2022 IEEE 33rd Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC), Kyoto, Japan, 2022, pp. 509-514, doi: 10.1109/PIMRC54779.2022.9977750.
- [13] R. Kudo, M. Cochrane, K. Takahashi, T. Inoue, K. Mizuno, "Experimental Validation of Link Quality Prediction using Exact Self-status of Mobility Robots in Wireless LAN Systems," IEICE Trans. On Communications, 2020.
- [14] R. Kudo, K. Takahashi, T. Inoue, and K. Mizuno, "Using vision-based object detection for link quality prediction in 5.6-GHz channel," J Wireless Com Network 2020, 207, 2020
- [15] <http://wiki.ros.org/navigation>
- [16] A. Tirumala, "Iperf: The TCP/UDP bandwidth measurement tool, "1999. [Online]. Available: <https://iperf.fr>