

フィジカル空間情報を用いた 28 GHz セルエリアにおける 5G スループット予測技術

永田 尚志[†] 工藤 理一[†] 高橋 馨子[†] Ramesh Eshan[†] 小川 智明[†]
青木 祐也^{††} 堀瀬 友貴^{††} 森広 芳文^{††}

[†] NTT 未来ねっと研究所フロンティアコミュニケーション研究部 〒239-0847 神奈川県横須賀市光の丘 1-1
^{††} NTT ドコモ 6G ネットワークイノベーション部 〒239-8536 神奈川県横須賀市光の丘 3-5 NTT ドコモ R&D
センタ

E-mail: †hisashi.nagata@ntt.com

あらまし 無線通信技術の発展に伴い、あらゆるモノがネットワークに接続され、年々、モバイルトラフィックは増加している。膨大なモバイルトラフィックに対応するためには、ミリ波のような高周波数帯の利用により無線システムの帯域幅を拡大することが有効である。その一方で、高周波帯の通信は、電波の直進性が強いこと、遮蔽によりリンク品質を著しく低下させる可能性がある。本稿では、通信端末と周辺物体の双方が移動する複雑な環境において、フィジカル空間情報として通信端末と周辺物体の位置・速度・方向を用いた 5G スループット予測技術の効果を、屋内の実環境において検証する。提案手法は、通信端末と周辺物体の物理環境の動きとスループットの関係をディープニューラルネットワークにより学習することで、未来のスループットの変動を予測する技術となる。屋内実験には、自律型移動ロボットを用い、ランダム性のある動作を行わせ、28 GHz チャネルのセルエリアにおいて、5G 商用網を用いたスループット計測を実施、スループットの予測性能を評価した。実験結果により、過去のスループットを用いた予測方法に比べ、14.6 % の精度向上を確認した。

キーワード 5G, ミリ波, ディープニューラルネットワーク, フィジカル空間情報, 通信品質予測

5G throughput prediction technology in 28 GHz cell area using physical space information

Hisashi NAGATA[†], Richi KUDO[†], Kahoko TAKAHASHI[†], Ramesh ESHAN[†], Tomoaki OGAWA[†],
Yuya AOKI^{††}, Yuki HORISE^{††}, and Yoshifumi MORIHIRO^{††}

[†] Frontier Communication Laboratory, NTT Network Innovation Laboratories 1-1 Hikarinooka Yokosuka-Shi
Kanagawa, 239-0847 Japan

^{††} 6G Network Innovation Department, NTT DOCOMO, INC. NTT DOCOMO R&D Center, 3-5 Hikarinooka
Yokosuka-Shi Kanagawa, 239-8536 Japan

E-mail: †hisashi.nagata@ntt.com

Abstract With the development of wireless communication technology, every thing is connected to the network, and mobile traffic is increasing year by year. In order to deal with enormous mobile traffic, it is effective to expand the bandwidth of wireless systems by using high frequency bands such as millimeter-wave (mmWave). On the other hand, the link quality in the high-frequency band can be significantly degraded by shielding due to the strong linearity of the radio waves. In this paper, we verify 5G throughput prediction technology using the position, velocity, and direction of a communication terminal and surrounding objects as physical space information in a complex environment where both a communication terminal and surrounding objects move. The proposed technique predicts future throughput fluctuations by learning the relationship between throughput and the movement of the communication terminal and surrounding objects in the physical environment using a deep neural network. In the indoor experiment, we used an autonomous mobile robot to perform random movements, measured throughput using 5G commercial networks in 28 GHz cell area, and evaluated the throughput prediction performance. Experimental results show a 14.6 % improvement in accuracy compared to previous throughput-based predicting methods.

Key words 5G, millimeter-wave, deep neural network, physical space information, communication quality prediction

1. ま え が き

無線通信システムの発展により、高速、大容量、多数端末接続、高信頼、低遅延などの要件を満たす 5G システム [1], [2] が実用化され、広く利用されつつある。5G により、幅広いアプリケーションやサービスが多様な業界で生み出されることが期待されている [3]。一方、このような無線通信品質の進歩に伴い、年々、接続されるデバイスとモバイルトラフィックは増加している [4]。それをカバーするため、ミリ波チャネルのような高周波帯を利用していく必要がある [5]。ミリ波やサブテラヘルツ波は、将来のネットワーク基盤を支える鍵となっている [6]。

ミリ波による無線通信は、理想的な見通しの環境下では高いパフォーマンスを実現するが、障害物などの影響による見通し外の環境下では、品質が著しく低下する可能性がある [7]。このようにミリ波通信は、利用ユーザやその周辺物体の移動によりアプリケーションの品質やパフォーマンスに大きな影響を受けやすい [8]。

ミリ波での高信頼な無線通信を実現するため、西尾らは [9], [10]、人が通信を遮蔽する歩行シナリオに対して、深度カメラから取得した RGB-D イメージや Light Detection And Ranging (LiDAR) から取得した点群データを用いて、convolutional neural network (CNN) による受信電力予測を提案している。これらの研究は、アクセスポイント (AP) と固定されたステーション (STA) との間で 60 GHz 帯の無線通信している屋内環境で、人の非周期な遮蔽による品質低下に対する 500 ms 以上先の長期予測にアプローチしている。しかし、人とステーションの双方がランダム性を持って移動するような複雑な環境は検討されていない。このような環境では、遮蔽は時間だけでなく場所に対してもランダムに発生し、無線通信品質を学習させることは困難となる。

我々の以前の研究では [11]~[14]、自律型移動ロボットに掲載した 5 GHz 帯の Wi-Fi に接続した通信端末のスループット予測に関して、定点カメラからの RGB イメージから推定した自律型移動ロボットのバウンディングボックス位置情報などのフィジカル空間情報の有効性を確認した。これらの研究では、RGB イメージや位置情報などのフィジカル空間情報が無線通信品質と高い相関性があり、数百ミリ秒以上先の長期予測に対して効果的であることを示している。さらに、[15], [16] では、屋内での 28 GHz セルエリアにおける商用の 5G に対して、2 人の歩行者の一方がユーザ端末 (UE) を所持し、他方はそれを遮蔽するように双方がランダム性を持って動く歩行シナリオで、フィジカル空間情報を用いたスループット予測を検討した。本稿では、さらに遮蔽のために 2 人の歩行者を用意し、より人による遮蔽の頻度や効果が高い歩行者シナリオに拡張し、フィジカル空間情報を用いた DNN による 5G スループット予測の効果を検証した。

予測精度の評価のため、自律型移動ロボットと人体の比誘電率・導電率を模擬した人形を組み合わせた人型ロボットで歩行者を再現し、歩行シナリオにおけるフィジカル空間情報を自動で収集可能な 5G 検証フィールドを屋内環境に構築し、DNN に

必要となるビッグデータを収集した。この自律型移動ロボットは robot operationing system (ROS) [17] により、移動と停止をランダムに繰り返すようにランダム性を与えて走行させた。また、3 台の人型ロボットのうちの 1 台には UE を掲載し、5G 基地局を通じてクラウド上のサーバと通信をさせてスループットを計測し、そのときの 5G スループットを予測させた。残り 2 台については、UE を所持した人型ロボットの周囲を移動し、遮蔽が発生するように制御した。実験は 17 日間にわたる計約 48 時間に相当するデータセットを取得し、予測の学習に用いた。

本稿では、2 章でシステムモデルと予測モデルとその入力データであるフィジカル空間情報の概要について、3 章では、提案手法を評価した屋内実験環境の紹介と、フィジカル空間情報を用いた予測モデルの入力データの詳細説明について、4 章では、提案手法の予測精度を評価について、5 章で結論を述べる。

2. システムモデル

システムモデルはの全体像は図 1 の通りである。歩行者がユーザ端末 (UE) を所持し、アプリケーションを利用している場面を想定し、それをロボットで再現した。UE はサービス利用のために 5G 基地局と通信している。このシステムでは、フィジカル空間情報として予測対象の UE とその周辺物の位置・方向・速度の状態とリンク品質を収集して、予測モデルに入力して将来のリンク品質を予測する。

数秒後の予測されたリンク品質は仮想現実 (VR) や拡張現実 (AR) のような多様なアプリケーションを安定的に利用するために活用される。本稿では、5G システムに焦点を当て、リンク品質における数秒後などの長期予測を検討する。

2.1 リンク品質

リンク品質は 5G システムにおいて、時間幅 ΔT の平均スループットとして定義する。時刻 t_i のときの時間幅 ΔT におけるスループット $R[t_i]$ は、

$$R[t_i] = \frac{1}{\Delta T} \sum_{t_i - \Delta T < t \leq t_i} B[t], \quad (1)$$

と表現できる。 $B[t]$ は時刻 t において受信できたビット量である。予測時間を t_m とすると、予測するスループット $R[t_m]$ となる。現在時刻を t_0 とすると、現在時刻との差である $t_m - t_0$ 秒後を予測することを意味する。

2.2 フィジカル空間情報

本システムモデルでは、フィジカル空間情報として各ロボットの位置と方向、速度を取得し、それらを用いて各ロボットの状態を ϕ で定義する。時刻 t における予測対象の UE を所持させたロボット A の状態を $\phi_A[t]$ 、ロボット A の周囲で移動する遮蔽用のロボット B と C の状態をそれぞれ $\phi_B[t]$, $\phi_C[t]$ と定義する。各ロボットの位置と方向、速度は、無線リンクやカメラ、センサを経由して取得される。本稿では、予測対象の UE を所持したロボット A と遮蔽用のロボット B と C を用意し、2 次元のフィジカル空間情報が利用できる環境を想定する。そのため、各ロボットの高さ方向は考慮されない。時刻 t における各ロボットの状態は、

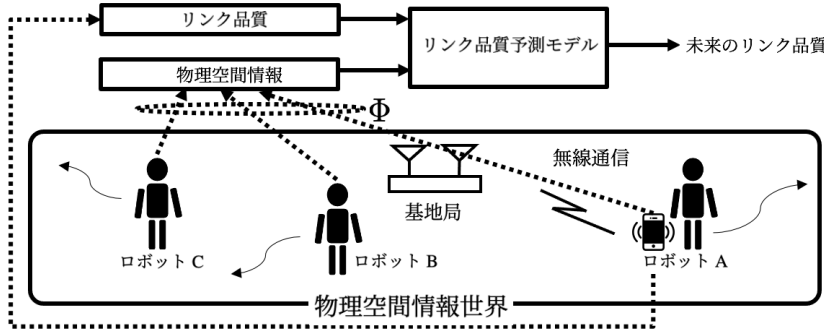


図1 システムモデル

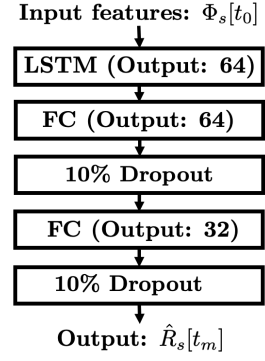


図2 スループット予測モデルのDNN構成

$$\phi_A[t] = \{x_A[t], \theta_A[t], v_A[t]\}, \quad (2)$$

$$\phi_B[t] = \{x_B[t], \theta_B[t], v_B[t]\}, \quad (3)$$

$$\phi_C[t] = \{x_C[t], \theta_C[t], v_C[t]\}, \quad (4)$$

で与えられ、 $x[t], \theta[t], v[t]$ は、ロボットに対する位置ベクトル、方向ベクトル、速度ベクトルを表す。これらのロボットの状態の詳細は3.章で議論する。

2.3 スループット予測

5Gのリンク品質予測に対して、フィジカル空間情報を用いた提案手法との比較のため、スループット情報を用いた予測手法と比較評価を行った。リンク品質として5Gのスループットを扱った。スループット予測モデルは過去のスループットと予測対象のUEの状態と、遮蔽用UEの状態を用いる。本稿では、 $\Phi_T, \Phi_A, \Phi_{AB}, \Phi_{ABC}, \Phi_{ABCT}$ の5つの入力データを用いてスループット予測を評価した。入力データはそれぞれ、

$$\Phi_T = \{R[t] \mid -D+1 \leq t \leq 0\}, \quad (5)$$

$$\Phi_A = \{\phi_A[t] \mid -D+1 \leq t \leq 0\}, \quad (6)$$

$$\Phi_{AB} = \{(\phi_A[t], \phi_B[t]) \mid -D+1 \leq t \leq 0\}, \quad (7)$$

$$\Phi_{ABC} = \{(\phi_A[t], \phi_B[t], \phi_C[t]) \mid -D+1 \leq t \leq 0\}, \quad (8)$$

$$\Phi_{ABCT} = \{(\phi_A[t], \phi_B[t], \phi_C[t], R[t]) \mid -D+1 \leq t \leq 0\}, \quad (9)$$

とし、 Φ_T は過去スループット、 Φ_A はUEを所持したロボットAの状態、 Φ_{AB} はロボットA, Bの状態、 Φ_{ABC} はロボットA, B, Cの状態、 Φ_{ABCT} はロボットA, B, Cの状態に過去スループットを時系列データとし、それらを入力してスループットを予測させた。時刻 t_0 における入力データ $\Phi_s[t_0]$ から将来のスループット $\hat{R}_s[t_m]$ を予測するモデルを生成するために用いられ、その将来スループットを出力する関数 f_s は、

$$\hat{R}_s[t_m] = f_s(\Phi_s[t_0]), \quad (10)$$

で与えられる。インデックス $s \in \{T, A, AB, ABC, ABCT\}$ は5種類の入力データを表す。

各々の入力データに対する予測モデルのスループット予測精度を評価するため、平均絶対誤差(MAE)の指標を用いる。入力データ Φ_s に対するMAEは、

$$MAE_s = \sum_k |R[t_k] - \hat{R}_s[t_k]|, \quad (11)$$

となり、インデックス k はテストデータを表しており、全てのテストデータの誤差を合計して平均した値で評価を行う。

2.4 スループット予測モデル

スループット予測モデルのDNN構成を図2に示す。予測モデルには、Recurrent Neural Network (RNN)とFC (Fully Connected)の層から構成されるDNNを用いる。第1層のRNNにはa Long short-term memory (LSTM)、第2層と第3層にはFC層を用いており、出力次元数はそれぞれ64, 64, 32としている。また、FC層の間には10%のドロップアウト、FC層の出力には活性化関数としてRectified Linear Unit (ReLU)を用いている。最適化アルゴリズムにはAdaptive Moment Estimation (Adam)、学習率は0.0005とした。損失関数にはスループット観測値と予測値の平均二乗誤差(MSE)とし、それを最小化するように訓練した。

3. 屋内実験環境

5Gスループット予測精度を評価するために、屋内に5G検証フィールドを構築した。屋内に3人の歩行者がいて、その内の1人がUEを所持して、28GHzチャンネルのセルエリアの5G経由で通信しているような歩行者シナリオを想定した。

歩行者シナリオに対して、DNNで構成されるスループット予測モデルを学習させるために必要となるビッグデータ生成のため、図3の通り、自律走行する人型ロボットを3台用意した。人型ロボットは人形と台車ロボットの組み合わせで構成される。人形は人体の比誘電率・導電率を模擬したものであり、土台の台車ロボットにより歩行を再現させた。台車ロボットは対向2輪型で、LiDARを搭載しており、周辺環境情報を2次元点群データとして取得して障害物との衝突を回避して安定的な連続走行を可能としている。ロボットAのバックパックの中にUEを設置している。

図4は、実際の屋内実験環境のマップである。図4に示す通り、各ロボットは異なる2つずつのゴール地点を設定しており、ロボットAとBとCについて、それぞれ $x = (6.0, -2.5), (6.0, 4.5)$ と $x = (5.0, -2.5), (5.0, 3.0)$ と $x = (0.0, -2.0), (4.0, -2.0)$ がゴール地点の座標である。各ロボットはこれらのゴール地点を端点としてその間を往復直線運動するようにROSで制御している。



図3 ロボット; 人体の比誘電率・導電率を模擬したロボットを3台用意し、それぞれランダム性を与えて往復直性走行させた




図4 屋内実験環境マップ

また、走行中にランダムに移動と停止をするように制御し、走行にランダム性を与えている。実際の走行ルートはロボット A, B, C について、それぞれ図4の赤線と青線と緑線となる。ロボット B, C はロボット A と基地局の間を走行するように設定しており、ロボット A と基地局の間の見通しを遮る事象がランダムに発生する。また、全てのロボットは最高速度を 1.0 m/s で走行させている。

3.1 スループット計測

表1は通信に関する実験諸元を表している。5G スループット計測には iperf[18] のツールを活用し、商用網の 5G 基地局を経由して UE-A とクラウド上のサーバとの間でアップリンクで UDP によりパケット転送することで 0.1 s 間隔で収集した。収集したスループットは、時間幅 $\Delta T = 1.0s$ で平均化して利用した。アンテナ高については、5G 基地局は 2.65 m で、ロボット A の UE は 1 m の高さである。

3.2 フィジカル空間情報と測定

ロボットの土台である台車ロボットには LiDAR が搭載されており、レーザ信号の反射点による点群データに対して Adaptive

表1 実験諸元

基地局	28 GHz チャンネルのセルエリアにおける商用網 5G
アンテナ高	ロボット A の UE: 1.0 m 基地局: 2.65 m
トランスポートプロトコル	UDP
伝送	Uplink




図5 ロボットシステム情報; 時刻 t における (a) 位置と方向, (b) 回転・進行方向速度

Monte Carlo Localization (AMCL) に基づいたアルゴリズムを適用することで、点群データとフィールドマップとの比較により自己位置・方向・速度を推定する。台車ロボットから得られる状態は図5に示す。時刻 t のときの位置ベクトル $\mathbf{x}[t]$ は $\mathbf{x}[t] = \{x[t], y[t]\}$ と表現される。時刻 t のときの速度ベクトル $\theta[t]$ は

$$\theta[t] = (k[t], \omega[t]) = (\sin(\theta[t]/2), \cos(\theta[t]/2)), \quad (12)$$

で与えられ、 $\theta[t]$ は方位角を表す。さらに、時刻 t のときの速度ベクトル $\mathbf{v}[t]$ は、

$$\begin{aligned} \mathbf{v}[t] &= (v[t], \dot{\theta}[t]) \\ &= (L(\omega_1[t] + \omega_2[t])/2, L(\omega_1[t] - \omega_2[t])/2), \end{aligned} \quad (13)$$




図6 5回の交差検証を実施したときの入力データごとの絶対平均誤差 (最小, 平均, 最大)

で与えられ, L は車輪半径, d は2つの車輪間の軸方向距離, ω_1 と ω_2 はそれぞれ左右の車輪の角速度である. 各ロボットからこれらの状態を収集した.

3.3 訓練と精度評価のためのデータセット

5G スループットと各ロボット A, B, C の状態を 0.1 s 間隔で収集した. 構築した屋内の 5G 検証フィールドで 17 日間にわたり実験を行い, 計約 48 時間に相当する 1,732,233 サンプルのデータセットを用意した. これらのデータセットの値は学習のために, 0 から 1, または -1 から 1 の範囲でスケールしている. また, 学習は 5 回の交差検証を実施しており, 全てのデータセットの内の 25 % のサンプルをテストデータ, それ以外のデータセットの内の 90 % のサンプルを訓練データ, 10 % のサンプルを評価データとして学習させた.

5G スループットに関しては, 最小値が 1.1 Mbps で, 最大値が 1.7 Gbps で, 平均値が 182 Mbps であった. このように高いスループット値が観測されており, ロボット A は 28 GHz チャンネルの 5G に接続されていたことがわかる. スループットについては時間幅 $\Delta T = 1.0$ s, つまり 10 フレーム分で移動平均をとる. また, スループットの上限を 200 Mbps に設定し, スループット低下に焦点を当てた予測を行なった.

4. 評価結果

DNN に基づく 5G スループット予測モデルに対する入力データは, 過去のスループットと UE の状態の組合せで構成される 5 種類を用意した. 入力データは 1.0 s 間に相当する $D = 10$ とし, 10 フレーム分の時系列データとした.

4.1 5G スループット予測モデルに関する精度評価

図 6 は, 5 回の交差検証を実施したときのスループットの予測値と観測値との間の最小, 平均, 最大の MAE をプロットした. $\Phi_A, \Phi_{AB}, \Phi_{ABC}, \Phi_{ABCT}, \Phi_T$ の入力データに対して, 5 回の MAE の平均値はそれぞれ, 28.3, 27.5, 24.9, 19.9, 23.3 Mbps となった. 提案手法である Φ_{ABCT} と過去スループットのみを入力した従来手法である Φ_T を比較し, 提案手法は 14.6 % 精




図7 絶対誤差に関する CDF

度向上した. この結果から, 5G スループットの長期予測に対して, フィジカル空間情報は有効であることがわかった. また, ロボット A のみだけでなく, ロボット B, C の状態を加えることで, 予測精度は 12.0 % 精度向上した.

図 7 は, スループットの予測値と観測値との間の絶対誤差に対する累積分布関数 (CDF) を示している. $\Phi_A, \Phi_{ABC}, \Phi_{ABCT}, \Phi_T$ の入力データに対する 50 パーセンテイル値はそれぞれ 15.5, 15.2, 11.6, 13.2 Mbps, 80 パーセンテイル値はそれぞれ 53.1, 47.6, 38.7, 45.3 Mbps となった. Φ_A と Φ_{ABC} を比較し, 80 パーセンテイル値で 10.4 % 精度向上している. 大きなスループット誤差を周辺情報を用いることで低減できることがわかる. また, 提案手法である Φ_{ABCT} と過去スループットのみを入力した従来手法である Φ_T を比較し, 提案手法は 50 と 80 パーセンテイル値でそれぞれ 11.9, 14.6 % 精度向上し, フィジカル空間情報の有効性が確認できた.

4.2 入力データ評価

図 8 は, スループットの予測値と観測値を時系列に 100 ms 間隔でプロットした結果である. 黒の実線は観測値を示しており, 200 Mbps から 50 Mbps に急激にスループットが低下する箇所がある. 赤と青の点線は, それぞれ Φ_A と Φ_{ABC} を入力して予測した結果である. 8 のグレー部分で, 双方の予測結果が大きく異なることがわかる. Φ_{ABC} ではスループットの低下を予測ができていないが, Φ_A では予測ができていない. これらの




図8 スループットの観測値と予測値の時系列プロット結果

箇所でのスループット低下は、ロボット A の周囲を動くロボット B, C の遮蔽によるものであり、ロボット B, C の状態を入力することで遮蔽効果を学習できたためだと考えられる。

5. 結 論

本稿では、通信端末と周辺物体の双方が動く複雑な環境下での、フィジカル空間情報を用いた 28 GHz チャンネルに対する 5G スループット予測技術を提案した。予測モデルには、LSTM と FC 層から構成される DNN を用いた。提案手法では、フィジカル空間情報として通信端末の位置・方向・速度だけでなく、その周辺情報を加えた手法を提案した。DNN の学習に必要なビッグデータを収集するため、人体の比誘電率・導電率を模擬した人形と、ROS で制御した台車ロボットを組み合わせた人型ロボットを用いて、自動的にフィジカル空間情報を収集可能な 5G 検証フィールドを屋内に構築した。17 日間にわたる計 48 時間の計測に相当する 1,732,233 サンプルを収集し、通信端末だけでなく周辺のフィジカル空間情報が 5G スループット予測に効果的であることを示した。評価指標の MAE に関して、過去スループットのみを入力する従来技術と比較して、通信端末とその周辺のフィジカル空間情報を用いることで 14.6 % 精度向上した。

文 献

- [1] T. Nakamura, S. Nagata, H. Umeda, H. Takahashi, and K. Ando, "Special Articles on LTE-Advanced Release 13 Standardization," NTT DOCOMO Technical Journal Vol. 18, No.2, 2016.
- [2] P.C. Jain, "Recent trends in next generation terabit Ethernet and gigabit wireless local area network," In Proc. Of 2016 International Conference on Signal Processing and Communication (ICSC), pp. 106-110. IEEE, 2016.
- [3] M. A. Lema et al., "Business Case and Technology Analysis for 5G Low Latency Applications," in IEEE Access, vol. 5, pp. 5917-5935, 2017, doi: 10.1109/ACCESS.2017.2685687
- [4] A. Gupta and R. K. Jha, "A Survey of 5G Network: Architecture and Emerging Technologies," in IEEE Access, vol. 3, pp. 1206-1232, 2015, doi: 10.1109/ACCESS.2015.2461602.
- [5] C. Dehos, J. L. González, A. De Domenico, D. Kténas, and L. Dussopt, "Millimeter-wave access and backhauling: the solution to the exponential data traffic increase in 5G mobile communications systems," IEEE Commun. Mag., vol. 52, no. 9, pp. 88-95, Sep. 2014.
- [6] https://www.docomo.ne.jp/english/binary/pdf/corporate/technology/whitepaper_6g/DOCOMO_6G_White_PaperEN_v5.0.pdf
- [7] Wang, X., Kong, L., Kong, F., Qiu, F., Xia, M., Arnon, S., and Chen, G, "Millimeter wave communication: A comprehensive survey," IEEE Communications Surveys and Tutorials, vol. 20, no. 3, pp. 1616-1653, » third quarter 2018.
- [8] J. Li, Y. Niu, H. Wu, B. Ai, S. Chen, Z. Feng, Z. Zhong, N. Wang, » "Mobility Support for Millimeter Wave Communications: » Opportunities and Challenges," IEEE Communications Surveys and Tutorials, vol. 24, no. 3, » pp. 1616-1653, third quarter 2022.
- [9] T. Nishio et al., "Proactive Received Power Prediction Using Machine Learning and Depth Images for mmWave Networks," in IEEE Journal on Selected Areas in Communications, vol. 37, no. 11, pp. 2413-2427, Nov. 2019, doi: 10.1109/JSAC.2019.2933763.
- [10] S. Ohta, T. Nishio, R. Kudo and K. Takahashi, "Millimeter-wave Received Power Prediction Using Point Cloud Data and Supervised Learning," 2022 IEEE 95th Vehicular Technology Conference: (VTC2022-Spring), Helsinki, Finland, 2022, pp. 1-5, doi: 10.1109/VTC2022-Spring54318.2022.9860728.
- [11] R. Kudo, M. Cochrane, K. Takahashi, T. Inoue, K. Mizuno, "Experimental Validation of Link Quality Prediction using Exact Self-status of Mobility Robots in Wireless LAN Systems," IEICE Trans. On Communications, 2020.
- [12] R. Kudo, K. Takahashi, T. Inoue, and K. Mizuno, "Using vision-based object detection for link quality prediction in 5.6-GHz channel," J Wireless Com Network 2020, 207, 2020
- [13] R. Kudo, K. Takahashi, T. Murakami, T. Ogawa, "Deep Learning based Link Quality Prediction for Autonomous Mobility Robots", IEICE Tech. Rep., vol. 120, no. 321, SIP2020-80, pp. 218-223, Jan. 2021.
- [14] H. Nagata, R. Kudo, K. Takahashi, T. Ogawa and K. Takasugi, "Two-step wireless link quality prediction using multi-camera images," 2022 IEEE 33rd Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC), Kyoto, Japan, 2022, pp. 509-514, doi: 10.1109/PIMRC54779.2022.9977750.
- [15] 永田尚志, 工藤理一, 高橋馨子, Eshan Ramesh, 小川智明, 青木祐也, 堀瀬友貴, 森広芳文, "フィジカル空間情報を用いた 5G スループット予測技術," 電子情報通信学会 2023 年 5 月センサネットワークとモバイルインテリジェンス研究会
- [16] Eshan Ramesh, Hisashi Nagata, Kahoko Takahashi, Riichi Kudo, Tomoaki Ogawa, "5G throughput prediction using LiDAR information," IEICE Technical Committee on Sensor Networks and Mobile Intelligence (SeMI), May. 2023.
- [17] <http://wiki.ros.org/navigation>
- [18] A. Tirumala, "Iperf: The TCP/UDP bandwidth measurement tool," 1999. [Online]. Available: <https://iperf.fr>